



Steht uns das Wasser bis zum Hals? Oder doch nur bis zu den Knien? -Modellierung und Visualisierung der Wasserstandsveränderungen am Neusiedler See mit SAS Viya





Gerhard Svolba, Data Scientist SAS, DACH Region

Data Scientist @SAS - <u>Medium</u> <u>LinkedIn</u> <u>Github</u> <u>SAS-Books</u> <u>SAS Articles</u> Youtube <u>DataPreparation4DataScience</u> <u>Data Science Use Cases</u>



Überblick

- Den fachlichen Hintergrund verstehen! (Auch in Zeiten von Deep Learning, GPUs, und Container Deployments

)
- Feature Engineering (auch bei scheinbar einfachen statistischen Fragestellungen)
- Warum auch ein langjähriger (SAS) Programmierer ab und zu gerne zu visuellen und interaktiven Oberflächen greift
- Manchmal darf es auch eine (einfache) Regressionsanalyse sein
- Bereitstellung und Illustration der Ergebnisse



Simulations-Szenarien für den Wasserstand des Neusiedler... SAS Software D-A-CH

SAS Communities Library We're smarter together. Learn from this collection of

Artikel-

DataPreparation4DataScience Data Science Use Cases

Historischer Tiefststand am Neusiedler See





21. Mai 2020 / BURGENLAND 1 619

Neusiedler See trocknet zunehmend aus

Der mittlere Wasserstand liegt unter dem langjährigen Tiefstwert. Nun wird wieder über eine Wasserzufuhr diskutiert



29. Mai 2020 / NEUSIEDLER SEE T 333

Grüne und WWF gegen Wasserzufuhr in den Neusiedler See

Landtagsabgeordneter Spitzmüller spricht von einer Gefahr für ein sensibles Natursystem, der WWF gar eine ökologische Katastrophe



26. Mai 2020 / KLIMASTATUSBERICHT \$\square\$ 823

Wie die Klimakrise Österreich erfasst: Dürre, Hitze und Starkregen häufen sich

Hitzesommer und Rekordniederschläge sind längst keine Ausnahme mehr. Künftig werden lange und extreme Wetterperioden laut Klimaforschern zunehmen



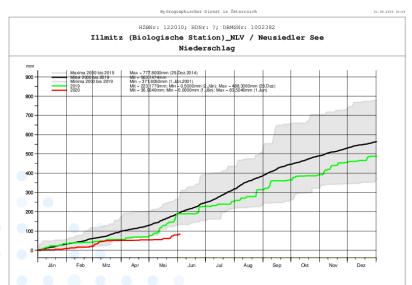


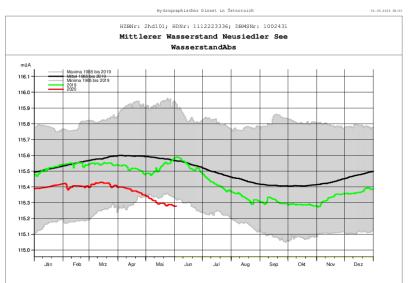




Wie kommt das?

- 80% -90% des Wasserhaushalts wird durch Regenwasser gespeist
- Jänner bis Mai 2020 waren extrem trocken.
- Karl Maracek (Hydrologie Burgenland): Niederschlag im Winter fördert den Aufbau von Wasserreserven (nur geringe Verdunstung)







Wie ist der Autor involviert?



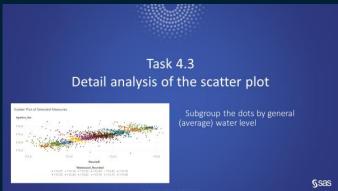


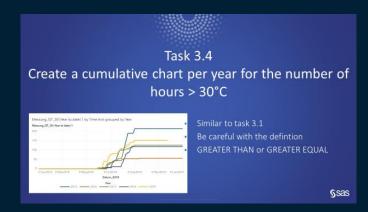


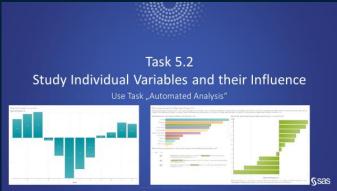


Analyse der hydrologischen Daten zum Neusiedler See im Rahmen meiner Lehrveranstaltung an der FH-Burgenland









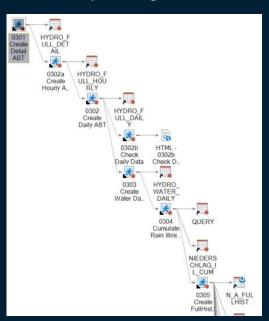


Überblick über die Vorgangsweise

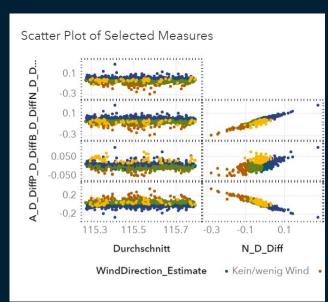
Laden der Daten von der Hydrologie Burgenland



Verknüpfen, Aggregieren Plausbilitätsprüfung, Aufbereiten



Deskriptive Statistiken, Kausalitätsanalysen, Simulationen





Wie wollen wir die Daten anordnen?

Wasser - Apetlon

Wasser - Illmitz

Temperatur - Illmitz

Wasser - Neusiedl (t)

Wasser – Neusiedl (t+1)

Niederschlag - Illmitz



(LONG) Longitudinal, Transactional

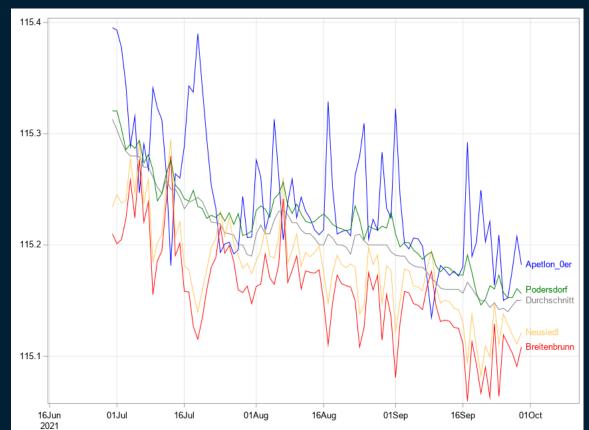
Wasser - Apetlon

Wasser - Illmitz

Wasser - Neusiedl

Temperatur - Illmitz

Niederschlag - Illmitz





Wie sieht unsere Datenstruktur (z.B für Korrelationsanalysen) aus? – WIDE Format

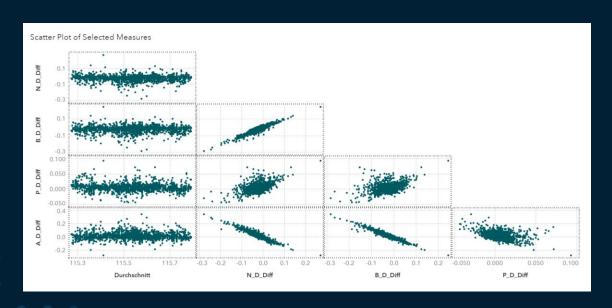
Wasser - Neusiedl

Wasser - Illmitz

Wasser - Apetlon

Temperatur - Illmitz

Niederschlag - Illmitz





Wie sieht unsere Datenstruktur aus?

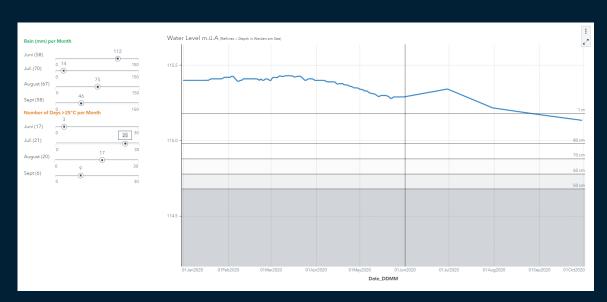
Mess-Stations Daten	Mess-Größen Daten	Wasser - Neusiedl
Mess-Stations Daten	Mess-Größen Daten	Wasser - Illmitz
Mess-Stations Daten	Mess-Größen Daten	Wasser - Rust
Mess-Stations Daten	Mess-Größen Daten	Temperatur - Illmitz
Mess-Stations Daten	Mess-Größen Daten	Niederschlag - Illmitz

Aggregations-Level?
15 min
Stündlich
Täglich
Monat



Use a regression model to explain and quantify the relationshiop between different factors







Daily data in a WIDE format

Wasser - Neusiedl

Wasser - Illmitz

Wasser - Apetlon

Temperatur - Illmitz

Niederschlag - Illmitz

Feature Engineering

```
*** Temperature;
Temp GT30 = (TempMax > 30);
Temp GT25 = (TempMax > 25);
*** Days Since Last Rain;
retain DaysSinceLastRain 0;
if RainSum > 0 then DaysSinceLastRain = 0;
else DaysSinceLastRain + 1;
*** Water Shift between North/South, East/West;
WShift N A = Water N - Water A;
WShift B P = Water B - Water P;
WShift R P = Water R - Water P;
WShift B I = Water B - Water I;
```

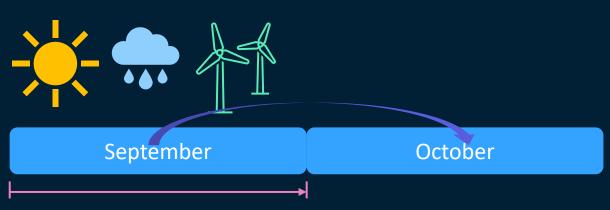


Aggregate from daily to a monthly level

```
select intnx('month', date, 0, 'Begin') as YYMM format = yymmp7.,
       month as month,
       mean (WaterLevel) as WaterLevelMean format=8.2,
       sum(WaterLevel*(day(date)=1)) as WaterLevel lofMonth format =8.2,
       sum(RainSum) as RainSum format = 8.,
       sum(RainSum > 0) as Cnt RainDays,
       max(DaysSinceLastRain) as MaxDaysSinceLastRain,
                                                             Observe which
       mean (TempMean) as TempMean format = 8.1,
       sum (Temp GT30) as Cnt TmpGT30 ,
                                                             aggregation
       sum (Temp GT25) as Cnt TmpGT25,
                                                             statistic you
       max (WShift N A) as WShift N A format=8.2,
                                                             should use for
       max (WShift B P) as WShift B P format=8.2,
                                                             each feature!
       max (WShift R P) as WShift R P format=8.2,
       max (WShift B I) as WShift B I format=8.2
```

Defining the Target Variable: Water_Level_Change

Sounds simple:
 The change between the actual and the next month ☺



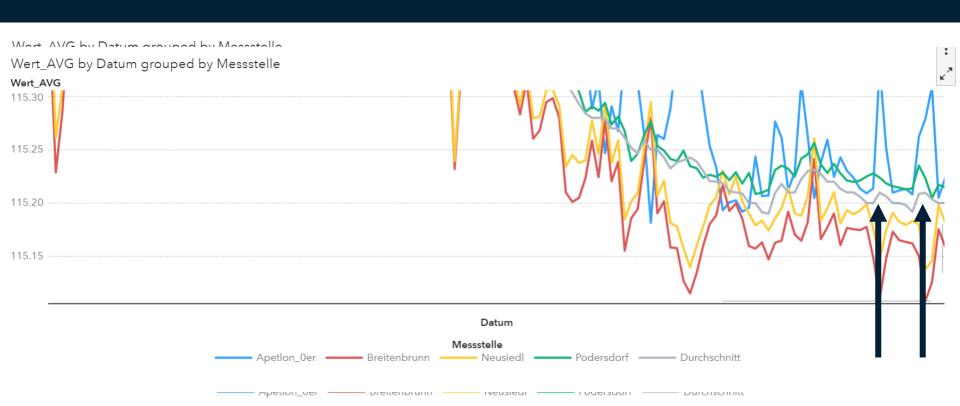
Or rather the value on the first day of the respective months?

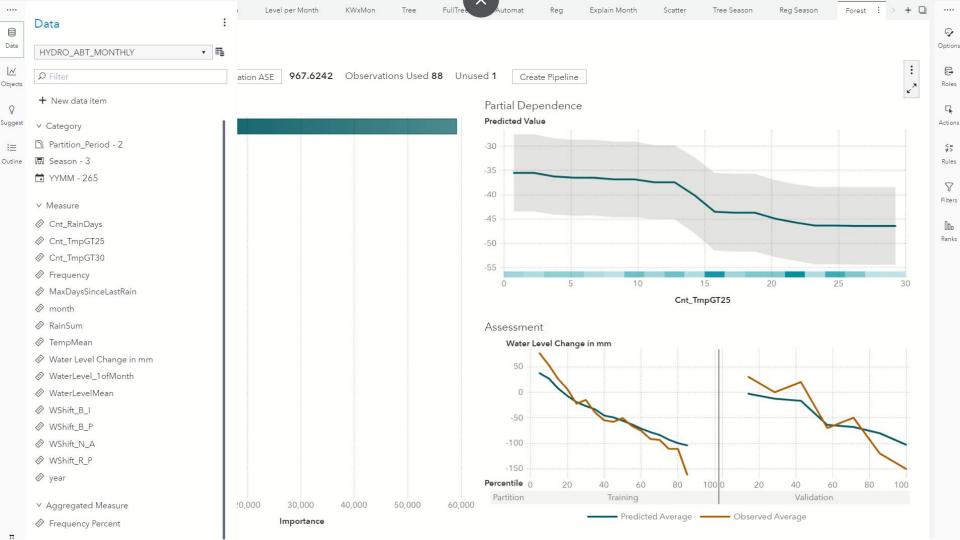
Comparing the mean of the actual and the next month???

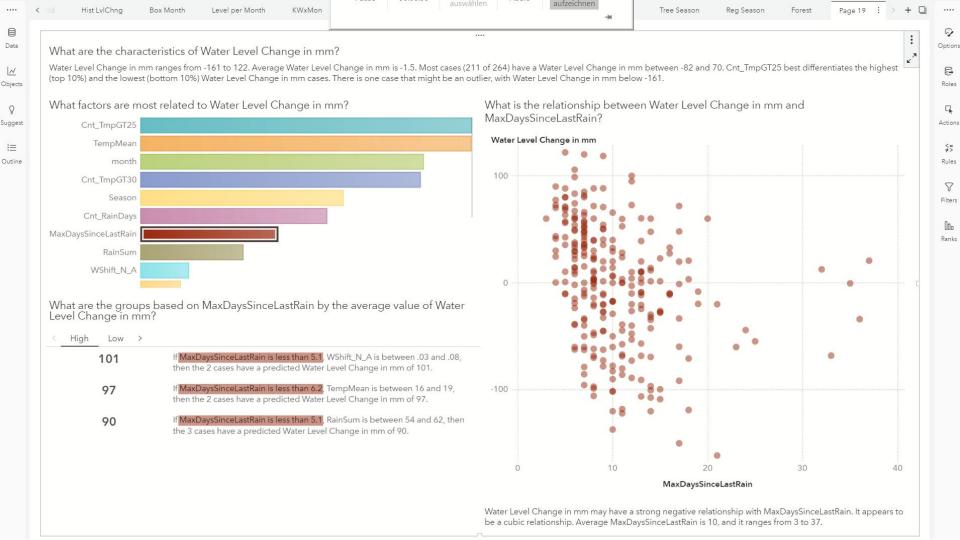


What is the true water level of the lake at a certain point in time?

Our target variable is slightly biased by the water shift caused by the wind







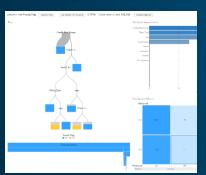
Use SAS/STAT (or SAS Visual Statistics) to train the model

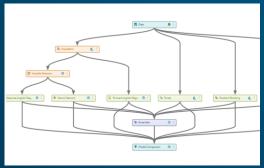
```
proc glmselect data=monthly abt month sort;
 model WaterLevelChange =
       WaterLevelMean RainSum Cnt Raindays
       MaxDaysSinceLastRain
       TempMean Cnt TmpGT30 Cnt TmpGT25
       WShift N A WShift B P WShift R P Shift B I
       /selection=backward;
 where month in (6,7,8,9) and year LE 2019;
 code file="&path.\Hydro WaterChange Mod1.0.sas";
run;
```



Ways how to interact with the SAS Analytic Platform

Graphical User Interface		Programming/Coding		
Visual Interface	Model Studio	SAS	OS Language	
Self-service analytical objects with options Easy integration with Model Studio & Model Manager	Pipelines and Nodes, specific analytical data preprocessing, more options & flexibility, Open Source integration, Easy integration with Model Manager	Fully flexible Procs and actions/actionsets, Open Source integration Easy integration with Model Manager	Fully flexible, SAS Integration: Access to CAS Procs, actions and actionsets (SWAT)	





```
proc gradboost data=cas1.fc review
     earlystop(tolerance=0 stagnation=5)
     numBin=20 binmethod=BUCKET
     maxdepth=6
     maxbranch=2
     minleafsize=5
     assignmissing=USEINSEARCH minuseinsearch=1
     seed=12345
  partition rolevar=_partind_ (TRAIN='1' VALIDATE='0');
  autotune useparameters=CUSTOM tuningparameters=(
     lasso(LB=0 UB=10 INIT=0)
     learningrate(LB=0.01 UB=1 INIT=0.1)
     ntrees(LB=20 UB=150 INIT=100)
     ridge(LB=0 UB=10 INIT=0)
     samplingrate(LB=0.1 UB=1 INIT=0.5)
     vars_to_try(LB=1 UB=7 INIT=7)
     searchmethod=GA objective=KS maxtime=900
     maxevals=50 maxiters=5 popsize=10
     targetevent='1'
```





Regression Results + Illustration

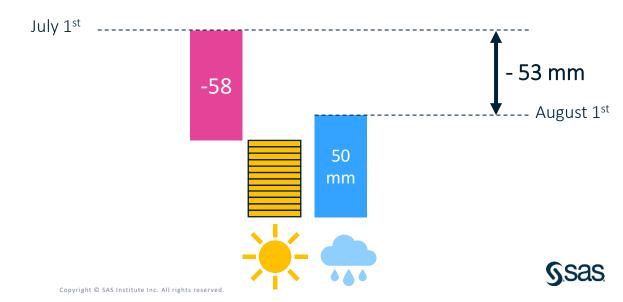
Parameter Estimates							
Parameter	DF	Estimate	Standard Error	t Value	Pr > t		
Intercept	1	-58 153454	7.587593	-7.66	<.0001		
RainSum	1	1.096672	0.062758	17.47	<.0001		
Cnt_TmpGT25	1	-3.330063	0.338838	-9.83	<.0001		

Average monthly water loss per summer month
Rain adds to the water level with a factor of ~ 1

Day >25 °C "costs" 3.3 mm of water level

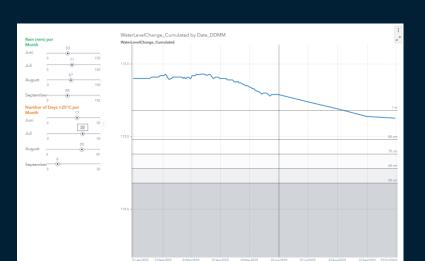
Example:

July, with 12 days > 25°C 50 mm rain

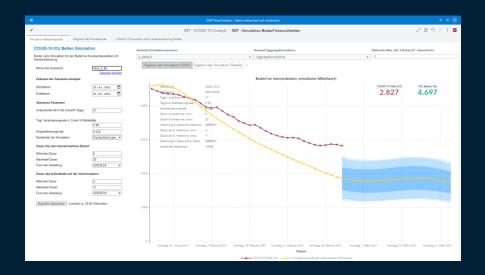


Using SAS Visual Analytics to interactively calculate prediction for different scenarios

Pre-Calculated Scenarios

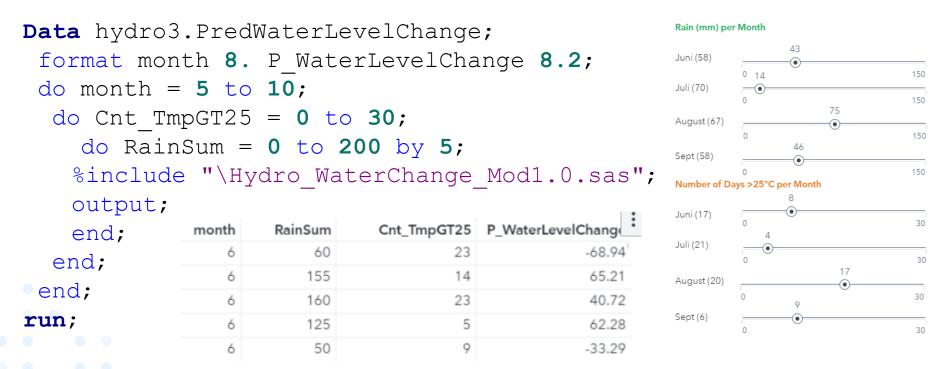


Scenario calculated on-the-fly





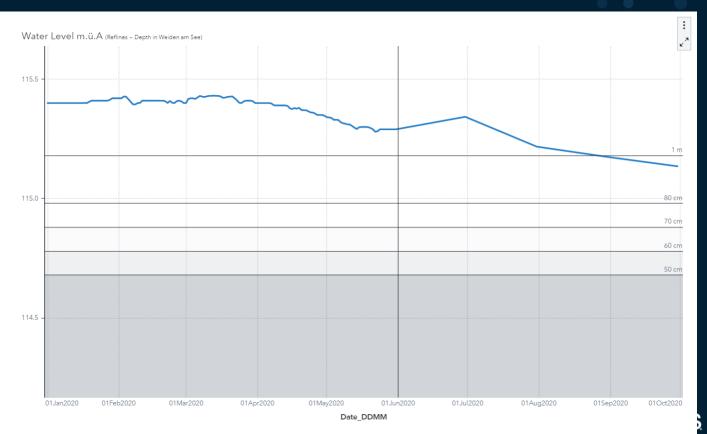
Pre-Calculate outcomes for all possible scenarios and filter according to the selected values





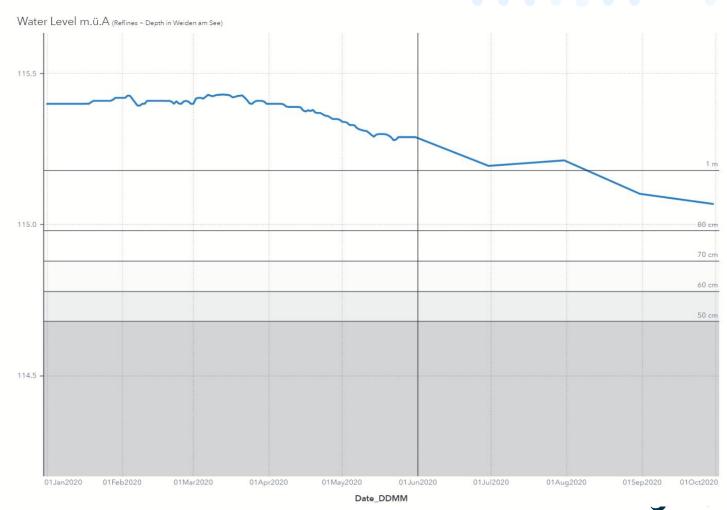
Using SAS Visual Analytics to interactively calculate prediction for different scenarios





Rain (mm) per Month





Was wäre wenn, das Wetter im Sommerhalbjahr so ist, wie ...

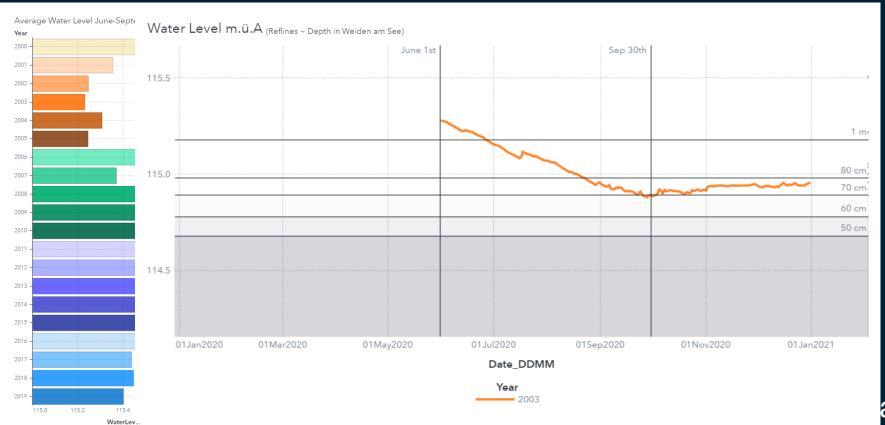
- im extrem trockenen Jahr 2003,
- im niederschlagsreichen Jahr 2014,

- ...

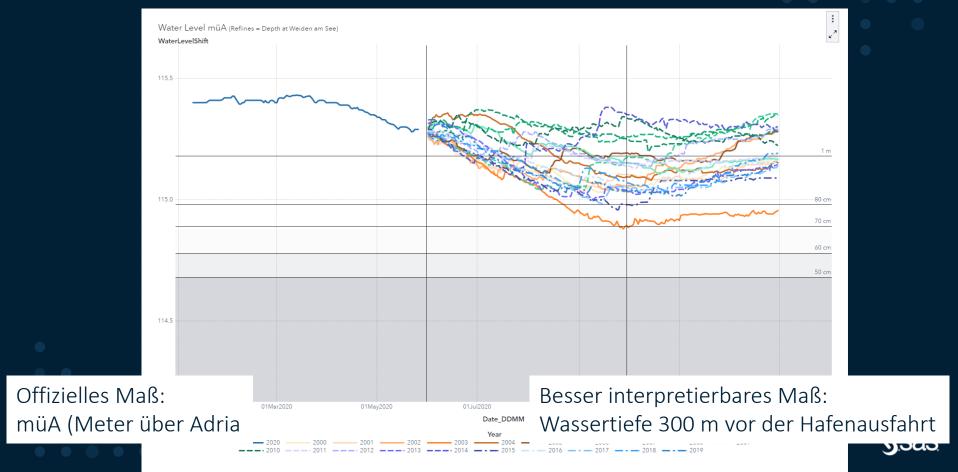




Interactive Display in SAS Visual Analytics: Selecting a bar on the left filters line chart on the right



Display Tipp: Use interpretable scales at your graph axes



Überblick

- Den fachlichen Hintergrund verstehen! (Auch in Zeiten von Deep Learning, GPUs, und Container Deployments

)
- Feature Engineering (auch bei scheinbar einfachen statistischen Fragestellungen)
- Warum auch ein langjähriger (SAS) Programmierer ab und zu gerne zu visuellen und interaktiven Oberflächen greift
- Manchmal darf es auch eine (einfache) Regressionsanalyse sein
- Bereitstellung und Illustration der Ergebnisse



Simulations-Szenarien für den Wasserstand des Neusiedler... SAS Software D-A-CH

SAS Communities Library We're smarter together. Learn from this collection of

Artikel-

DataPreparation4DataScience Data Science Use Cases

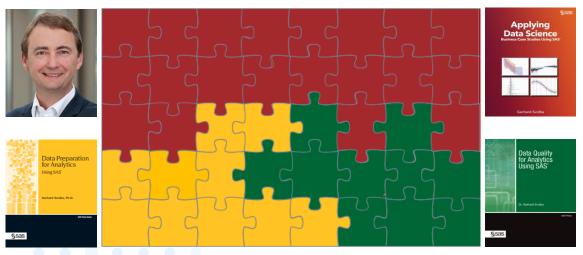
Zusammenfassung

- Den fachlichen Hintergrund verstehen!
 Für Feature Enginieerung, Modellbildung und Interpretation.
- Wer ist mein Auditorium? Wissenschafter, Data Scientists, Segler, ...
- Was ist die optimale Darstellungsart der Ergebnisse für diese Zielgruppe?
- SAS Visual Analytics unterstützt mich (> 25 Jahre SAS) in der Exploration der Daten und der Aufbereitung der Ergebnisse
- Und viele Fachanwender bei der kompletten Datenanalyse





Gerhard Svolba, Data Scientist @SAS mailto:sastools.by.gerhard@gmx.net



Articles and Blogs



Webinars



Tipps &





Macros & **Downloads**



